

磁共振扩散高阶张量成像的脑白质纤维微结构模型及特征提取算法

李 蓉 冯远静* 邵开来 王哲进

(浙江工业大学信息工程学院, 杭州 310000)

摘 要: 在基于扩散加权磁共振成像 (DW-MRI) 的脑白质纤维微结构建模中, 高阶张量成像模型 (HOT) 是解决常用二阶张量模型 (DTI) 难以刻画复杂纤维结构问题的新方法, 但是存在纤维特征方向提取复杂、计算量大等问题。本研究基于任意阶次的正定高阶张量理论, 提出一种能够快速获得任意阶张量纤维特征方向的迭代搜索算法。该方法根据张量模型的特征, 首先利用网格细分快速确定特征方向的大致区域, 进一步针对该区域进行细分, 从而迭代获得精确的高阶张量模型特征方向。该方法解决了现有符号计算方法易于陷入局部极值点或者搜索不收敛带来的误差和计算效率问题。为了测试所提出算法的有效性, 首先利用仿真数据分析了算法对不同数目、不同交角纤维的识别能力和特征方向的计算精度; 同时利用实际 DW-MRI 临床数据进行了测试。结果表明, 相比于现有的符号计算方法, 所提出的算法可以在 6 阶以及更高阶模型下获得稳定的纤维特征方向。

关键词: 高阶张量; 多纤维; 扩散张量磁共振成像

中图分类号 TP391 文献标志码 A 文章编号 0258-8021(2012)03-0365-09

Higher Order Tensor Imaging Model Feature Extraction Algorithm Based on Iterative Search

LI Rong FENG Yuan-Jing* SHAO Kai-Lai WANG Zhe-Jin

(College of Information Engineering, Zhejiang University of Technology, Hangzhou, 310000, China)

Abstract: In diffusion-weighted magnetic resonance imaging (DW-MRI) of white matter fiber microstructure modeling, higher order tensor (HOT) is a model to describe complex white matter fiber structures that the commonly used diffusion tensor imaging (DTI) model fails to describe. However some obstacles still exist in HOT such as complexity in extraction and large amount of calculation is required. Based on the HOT model, this paper presented a novel method of eigenvector extraction using subdivision theory and iterative search. In the first step, grid subdivision was used to roughly determine direction of the regional characteristics; next, accurate of high order tensor model features direction was obtained according to the area segmentation and iterative search. The method provided a solution to the problems including (1) symbols calculation method is likely to fall into the local extreme value point, (2) the search errors caused by no convergence and computational efficiency. In order to examine the efficacy of the proposed method, simulated data were used to analyze the recognition ability and the precision of eigenvectors in different numbers and different point of fiber cross cases. After that, evaluation was conducted using a real DW-MRI dataset. Compared with the existing symbols calculation method, stable fiber characteristic direction can be obtained by the proposed algorithm under 6th and higher order model.

Key words: higher order tensor; multi-fiber; diffusion-weighted magnetic resonance imaging (DW-MRI)

doi: 10.3969/j.issn.0258-8021.2012.03.09

收稿日期: 2011-10-18, 录用日期: 2012-03-23

基金项目: 国家自然科学基金(61075062); 浙江省重中之重学科开放基金(201100806)

* 通信作者。 E-mail: fyjing@zjut.edu.cn

引言

利用扩散加权磁共振成像 (diffusion weighted magnetic resonance imaging) 数据重构脑白质神经纤维是目前活体显示脑白质纤维走向的重要手段,它为研究脑白质的空间微结构开辟了崭新的途径,为脑的发育、精神分裂症、先天性与获得性脑白质病以及痴呆等的研究提供了新的方法。目前,常用的扩散张量估计方法是基于二阶扩散张量成像 (diffusion tensor imaging) 模型。其基本思想是利用 Stejskal-Tanner 信号转换模型估计 DW-MRI 得到扩散张量。但是,扩散张量成像模型的一个本质局限是假设每个体素 (voxel) 仅含一根神经纤维。实际 DW-MRI 数据的分辨率通常在 $3 \sim 15 \text{ mm}^3$ 之间,而纤维跟踪算法中的纤维束直径为毫米级,实际神经纤维直径为微米级^[11]。实际上, DW-MRI 体素中的神经纤维往往存在诸如交叉、分叉、扇型、瓶颈型等复杂结构。为了克服扩散张量模型的固有局限,高角度分辨率扩散磁共振成像 (high Angular resolution diffusion imaging, HARDI) 技术逐渐出现,如球面调和函数 (spherical harmonic, SH)^[1]、Q-ball 成像 (Q-ball imaging, QBI)^[2]、多张量模型 (multi-tensor model, MTM)^[3]、高阶张量模型 (high order tensor, HOT)^[4] 等,并已在世界范围内掀起了新的研究热潮。HARDI 技术的研究主要集中在解决纤维交叉问题,无法描述纤维分叉、扇型、瓶颈型等其他复杂结构。即使是纤维交叉,目前常用的 HARDI 模型仍然无法稳定的估计小角度纤维交叉以及多于 3 根纤维交叉的情形。其中,高阶张量模型^[5]作为 DTI 模型 (DTI 模型的实质是二阶张量模型) 的拓展,由于其简单的多项式形式便于计算得到纤维方向,得到了众多学者的关注。

Basser 于 2003 年首先利用一个高阶协方差张量进行频谱分解,得到二阶形式的特征值和特征向量^[6]。但是,这种方法只是对原有 DTI 模型的扩展,并不能描述复杂纤维。随后,Moakher 提出了一种利用低阶对称张量近似高阶张量的估计方法^[7]。如一个 3 维的 4 阶对称正定张量可以用一个 6 维的 2 阶对称正定张量来描述。但是,该方法低阶张量对高阶张量的近似并不完备。Barmapoutis 于 2007 年提出了利用 4 次 3 元多项式表示一个 4 阶张量的理论,并于 2008 年对其理论进行了补充,最终使得可以利用参数唯一确定的 4 次 3 元多项式表示整个 3 维 4 阶张量空间^[8]。在此模型的基础上,利用符

号数学法求取扩散函数 $d(g)$ 所有的极值点,从中选取得到特征方向。实际测试表明,该方法对于 2 阶、4 阶模型能稳定的获得纤维特征方向,而对于 6 阶甚至更高阶情形, Barmapoutis 没有深入研究,由于 $d(g)$ 函数的非线性特征,使其容易陷入局部极值点甚至搜索不收敛而无法得到特征方向。因此在实际应用中难以获得可靠的计算结果。

为了解决以上问题,本研究在 Barmapoutis 的求解任意阶次对称正定张量模型的统一框架的基础上^[4],依据细分与迭代搜索的思想,提出了一种计算任意阶次张量模型特征方向的新方法。并通过大量实验分析了此方法对不同数目、不同交角、不同信噪比条件下的纤维数量的识别能力和特征方向的计算精度。

1 任意阶次对称正定张量系数估计

1.1 任意阶次扩散张量

对于任意高阶张量模型,等式 (1) 中的扩散函数 $d(g)$ 可以用笛卡尔张量近似表示为

$$d(g) = \sum_{i=1}^3 \sum_{j=1}^3 \cdots \sum_{k=1}^3 \sum_{l=1}^3 g_i g_j \cdots g_k g_l D_{i,j,\dots,k,l} \quad (1)$$

式中, g_i 是三维单位向量 g 的 i 阶系数, $D_{i,j,\dots,k,l}$ 是张量系数,式 (1) 中指数的总和等于张量的阶次。当近似扩散函数时,要求任意阶次张量必须是全空间对称的。所以,对应于同一个单项式 $g_1^a g_2^b g_3^c$ 的张量系数彼此是相等的。例如 4 阶对称张量系数 $D_{1,1,1,1}$, $D_{1,1,2,1}$, $D_{1,2,1,1}$, $D_{2,1,1,1}$ 对应于同一个单项式 $g_1^3 g_2$,所以他们彼此相等。

1.2 正定张量参数化

任何对称正定多项式可以写成低阶多项式的平方和的形式^[9-10]。任意 3 个变量的 K 阶均匀多项式可以写成 $K/2$ 阶均匀多项式 $p(g_1, g_2, g_3; c)$ 的平方和的形式,其中 c 是包含多项式系数的向量。

$$d(g) = \sum_{j=1}^M p(g_1, g_2, g_3; c_j)^2 \quad (2)$$

式 (2) 中的参数化覆盖了任意阶次的对称正定均匀多项式空间。多项式 $p(\cdot)$ 的系数是未知的参数,其数目为 $\frac{1}{8} \left(\frac{(2+K/2)!}{(K/2)!} \right) + \frac{(2+K/2)!}{4(K/2)!}$, 即当阶次 K 为 2、4、6 时,对应的多项式的个数是 6、21 和 55。给定一组 DW-MRI 信号比 S_i/S_0 , 与其相关联的梯度方向 g_i 和扩散加权值 b_i (其中 $i = 1, \dots, N$), 可以通过最小化下面的能量函数估计 K 阶对称正定张量的系数^[4]。

$$E = \sum_{i=1}^N (S_i/S_0 - e^{-b_i d(g_i)})^2 \quad (3)$$

式中 $d(g)$ 由式(2)给定。

通过将式(2)化成球形卷积的形式最小化等式(3)中的能量函数

$$d(g) = \int_{S_{\frac{(2+K/2)-1}{2(K/2)-1}}} \lambda(c) p(g_1, g_2, g_3; c)^2 dc \quad (4)$$

式中, $\lambda(c)$ 是非负的实函数, 式(4)是式(2)的一般化, 它覆盖了整个 K 阶对称正定张量空间。将式(4)中的 $d(g)$ 带入式(3), 通过最小化式(3), 可以得到估计的扩散张量, 对式(4)在单位球体上离散积分下限, 这个函数的值可以由给定的一组 M' 个单位向量 $c_1, \dots, c_{M'}$ 近似。

$$d(g) = \sum_{j=1}^{M'} \lambda_j p(g_1, g_2, g_3; c_j)^2 \quad (5)$$

式中, λ_j 是非负的实数。通过构造足够多的合适的采样向量 c_j , 可以使 λ_j 达到需要的精度。

在高信噪比的情况下, 通过最小化能量函数式(3)可以得到正定张量。构造线性系统 $Px = y$, 其中, P 是 $N \times M'$ 矩阵, 且 $P_{ij} = -b_i p(g_i; c_j)^2$, y 是 N 维向量, 且 $y_i = \lg(S_i/S_0)$, x 是包含未知系数 λ_j 的向量。矩阵 P 的秩等于 K 阶张量的独立系数, 当 $K = 2, 4, 6, 8$ 时, 对应的系数个数为 6、15、28、45。 P 可以被分解为 $P = GC$, 其中 G 是由 g_i 构成的 $N \times \text{rank}(P)$ 矩阵。 C 是由 c_j 构成的 $\text{rank}(P) \times M'$ 多项式矩阵。最终, 可以由 Cx 计算得到 K 阶张量的独立系数。不同阶次张量系数的计算时间如表 1 所示, 由此表可知, 随着张量阶次的增加, 计算量增大, 张量系数计算时间呈指数趋势上升。

表 1 不同阶次张量系数计算时间

Tab. 1 Tensor coefficient calculation time of different order

	阶次				
	2	4	6	8	10
独立系数个数	6	15	28	45	91
时间/s	0.117	0.314	1.162	12.791	205.615

2 任意阶次张量模型特征方向估计

在实际测试中, Barmputis 提出利用符号数学法求取的所有极值点, 从而选取特征方向的方法^[6]局限性极大。首先, 利用符号数学法求解的极值, 得到包括极大值与极小值点, 事实上, 只需要极大值点。符号数学法虽然结果精确, 但计算速度相当

缓慢。在实际测试中, Intel 4 核 i5 2.4 GHz CPU 计算一个体素特征方向的计算时间在 3.26 s 左右。通常, 一个临床医学所用的全脑数据包含二百万至五百万体素, 用符号数学法计算过于费时。其次, 在局部噪声过大的情况下, Barmputis 的符号数学特征提取算法容易陷入搜索不收敛而无法找到极值的情况。Barmputis 对 6 阶以及更高阶次模型下特征方向提取没有深研究, 而且, 随着张量模型阶次增加特征提取受局部噪声影响程度增大。

鉴于此, 本研究提出一种全新的基于细分与迭代搜索的任意阶次张量模型特征方向的提取方法。首先, 对一个二十面体进行多次细分, 得到一个具有相邻点等距特性的离散球体。为方便数学计算, 建立图形的数据结构 $\text{Graph} = \{P, R_t\}$ 。定义

$$P = [P_1 \ P_2 \ \dots \ P_n]^T = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & \vdots \\ \vdots & \vdots & \ddots & 0 \\ 0 & 0 & \dots & 1 \end{bmatrix} \quad (6)$$

$$R_t = \begin{bmatrix} r_{11} & r_{12} & \dots & r_{1n} \\ r_{21} & r_{22} & \dots & r_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ r_{n1} & r_{n2} & \dots & r_{nn} \end{bmatrix} \quad (7)$$

式中, t 为细分次数, n 为 t 次细分后的离散点数量, $\{P\}$ 集合表示顶点集合, R_t 矩阵表示点集内部关系。细分过程如图 1 所示, 其中图(a)是待细分的二十面体; (b)~(d)分别是对该二十面体进行 1 次细分、2 次细分、3 次细分得到的离散球体, 且该离散球体上相邻点等距。

根据细分结果笔者选择第 3 次细分所得球面, 将离散球体点映射到体素模型上, 得到体素模型的离散模型, 如图 2 所示。则局部峰值点搜索公式为

$$\text{Peak} = \left\{ \sum_{i=1}^n \{d(g_i) > \max[d(P_i R_t)]\} \right\} \quad (8)$$

式中, Peak 为局部峰值点集合, $\max[\]$ 求取 $d(P_i R_t)$ 最大的点集合。搜索局部峰值点的分布情况可以得到所求的极大值点, 即可得到所需张量的特征方向。如图 3 所示。

取 4 阶张量模型在两根纤维交叉的情况下, 对二十面体进行不同次数的细分, 搜索局部峰值点, 并得到张量模型特征方向。分别将离散体素模型进行一次到五次细分, 结果如图 4 所示。由实验可知, 一方面, 细分次数越多, 误差越小。故增加细分次数有利于提高局部峰值的搜索精度。但另一方




图1 二十面体的细分过程。(a) 0次细分;(b) 1次细分;(c) 2次细分;(d) 3次细分

Fig. 1 Subdivision process of icosahedrons. (a) the icosahedrons; (b) 1 time segment; (c) 2 times segment; (d) 3 times segment




图2 映射过程。(a) 离散球体映射;(b) 离散体素模型

Fig. 2 Mapping process. (a) Mapping of discrete spheres; (b) The model of discrete voxel




图3 极值点搜索结果。(a) 搜索得到两个极值点;(b) 搜索得到4个极值点

Fig. 3 Extreme value point search results. (a) Two extreme value points; (b) Four extreme value points




图4 细分不同次后的张量模型及特征方向。(a) 1次细分;(b) 2次细分;(c) 3次细分;(d) 4次细分;(e) 5次细分

Fig. 4 Tensor model and characteristics direction of different subdivision. (a) 1 time segment; (b) 2 times segment; (c) 3 times segment; (d) 4 times segment; (e) 5 times segment

面,增加细分次数也将导致计算时间的增加。3次细分得642个点,4次细分为2562个点,6次就达到了40962个点,若一次性执行式(8)的计算,则计算非常耗时。

综合以上两方面,算法引入迭代机制,通过不断缩小所迭代区域的范围,在不明显增加计算量的基础上,可达到多次细分的效果。

3 高阶张量模型性能测试

为了研究高阶张量模型的纤维识别能力以及识别精度等性能,利用合成数据从3个方面进行实验分析。首先,当2根或者3根纤维在不同交角的情况下,利用不同阶次张量模型建模,分析不同情况下纤维的识别数目;其次,在2根或3根纤维交叉情况下,分析不同阶次的张量模型对不同交叉角度的纤维交角的识别误差,即张量模型的特征方向求取误差;最后,研究不同信噪比下,高阶张量模型对不同数目不同交叉角度的纤维识别误差。

利用人工合成数据测试算法的准确性。由于合成纤维路径可以事先设定,我们可以精确分析纤维识别能力和纤维跟踪误差。首先,对高阶张量模型的纤维识别能力进行分析,高阶张量模型可很好地解决一定角度范围内2根或3根纤维交叉的问

题。在求出任意阶次张量系数的基础上,利用所提出的基于细分与迭代搜索的算法对单一体素绘制张量模型并求得与极大值点对应的特征方向。经过多次实验得到不同阶次张量模型对 2 根和 3 根纤维在不同角度(θ)下的识别能力。

其次,对高阶张量模型的纤维识别误差进行分析。模拟 2 根或 3 根纤维交角分别为 90° 、 75° 、 60° 、 45° ,用所提出的基于细分与搜索的算法得到局部极大值点及对应的特征方向,绘制张量模型。经过多次实验,求取算法在不同阶次的情况下得出的特征方向误差。在上述的基础上,我们分析噪声对算法性能的影响。加入噪声对模拟的 DW-MRI 信号进行干扰。在不同的信噪比(SNR)下分析我们的特征提取算法对交叉纤维识别误差。

最后,用一组真实的 DW-MRI 数据进行分析,对比 DTI 成像方法说明高阶张量模型在复杂纤维结构下的局部张量模型的求解优势。

4 验结果分析

4.1 合成数据

在合成数据实验中,对单一体素模拟从 21 个梯度方向扫描,扩散敏感度系数 $b = 1\ 500\text{ s/mm}^2$ 。引

入 $\gamma = 5\%$ $\mu = 0^\circ$ 的高斯噪声对合成的 DW-MRI 数据添加扰动。图 5 为在两条纤维交叉的情况下,此算法得到的不同角度体素模型。由实验结果可以看出,首先,当 θ 在 $90^\circ \sim 75^\circ$ 之间时,均可准确识别两条纤维。其次,相对于 4 阶成像模型可以看出,适当提高模型阶次,对交角为 60° 的情况识别能力增强。但在两条纤维交角 θ 小于一定角度(约为 50°)时,单纯靠提高模型的阶次不能达到区分两条纤维的目的。

图 6 为在 3 条纤维交叉的情况下,算法得到的不同角度体素模型。当 $K = 6, 8, 10$, 3 条纤维交角互为 $90^\circ \sim 60^\circ$ 左右时,均能识别出 3 条纤维方向。与 2 条纤维交叉情况类似,在 3 条纤维交角小于一定角度时,提高阶次仍不能提高算法对纤维的识别能力。但是对比四阶模型可知,在纤维交角为 60° 时,适当提高阶次可提高纤维识别能力。

表 2 和表 3 为 2 根和 3 根纤维在不同阶次下算法对各种交叉角度的特征提取误差。当 K 大于 4,即当 $K = 6, 8, 10$ 时,算法对纤维的识别能力基本相同,随着张量模型阶次的变化,算法误差在一定水平上下浮动,由此可见算法精度基本保持在同一水平,并没有随张量模型阶次的增加呈线性变化趋势。




图 5 利用细分与迭代搜索算法得到两条纤维交角 θ 分别在 90° 、 75° 、 60° 、 45° 下的张量模型及所求解的特征方向

Fig. 5 Using subdivision theory and iterative search, we can get the tensor model and eigenvectors of two fiber crossing in 90° , 75° , 60° , 45°




图 6 利用细分与迭代搜索算法得到三条纤维交角 θ 分别在 90° 、 75° 、 60° 、 45° 下的张量模型及所求解的特征方向

Fig. 6 Using subdivision theory and iterative search , we can get the tensor model and eigenvectors of three fiber crossing $\theta = 90^\circ , 75^\circ , 60^\circ , 45^\circ$

表 2 2 根纤维在不同交角、不同阶次所求的特征方向误差(%)

Tab. 2 Eigenvectors error(%) in different θ and different order of two fibers

阶次	90°	75°	60°	45°
4	0. 00	0. 6	—	—
6	0. 00	0. 65	15. 1	—
8	2. 20	4. 59	17. 38	—
10	0. 00	4. 59	18. 52	—

表 3 3 根纤维在不同交角、不同阶次所求的特征方向误差

Tab. 3 Eigenvectors error in different θ and different order of three fibers

阶次	90°	75°	60°	45°
4	0	0. 87	—	—
6	0	1. 53	14. 74	—
8	1. 72	2. 17	7. 34	—
10	2. 13	10. 97	11. 2	—

模拟两束纤维以 75° 相交 ,纤维宽度为 3 个体素 ,其中纵向纤维起始点为 (14 ,1)、(15 ,1)、(16 ,1)。产生满足正态分布 $\gamma = 5\%$ $\mu = 0^\circ$ 、 $\gamma = 10\%$ μ

$= 0^\circ$ 、 $\gamma = 15\%$ $\mu = 0^\circ$ 的高斯噪声施加于此组 DW-MRI 数据上。选定跟踪起始点 (15 ,1) ,分别基于 DTI 模型和基于高级张量模型 ($K = 6$) 对 DW-MRI 数据实施纤维跟踪 ,记录跟踪路径与终点位置 ,结果见图 7。以施加的噪声干扰和建模模型为统计变量对结果进行统计 ,结果见表 4。

表 4 跟踪达到指定位置的纤维比例(%)

Tab. 4 The percentage (%) of fiber paths reaching the specified

高斯噪声参数	DTI 模型	高阶张量模型
$\gamma = 5\%$ $\mu = 0^\circ$	5. 1	99. 2
$\gamma = 10\%$ $\mu = 0^\circ$	4. 9	92. 2
$\gamma = 15\%$ $\mu = 0^\circ$	7. 8	89. 9

由图 7 和表 4 可知 ,在不同噪声背景下 ,基于高阶张量模型的纤维跟踪性能要优于基于 DTI 模型的方法。噪声越高 ,其性能优越性更明显。当噪音干扰增大至 $\gamma = 15\%$ 、 $\mu = 0^\circ$ 左右时 ,由 DTI 模型得到的跟踪纤维效果不理想 ,而高阶张量模型所得纤维受噪声干扰的影响不大 ,仍然保持较高的准确度。由此可见 ,在处理复杂纤维时 ,高阶张量模型能更准确地反映纤维形态 ,并在强噪声下保持较准确的

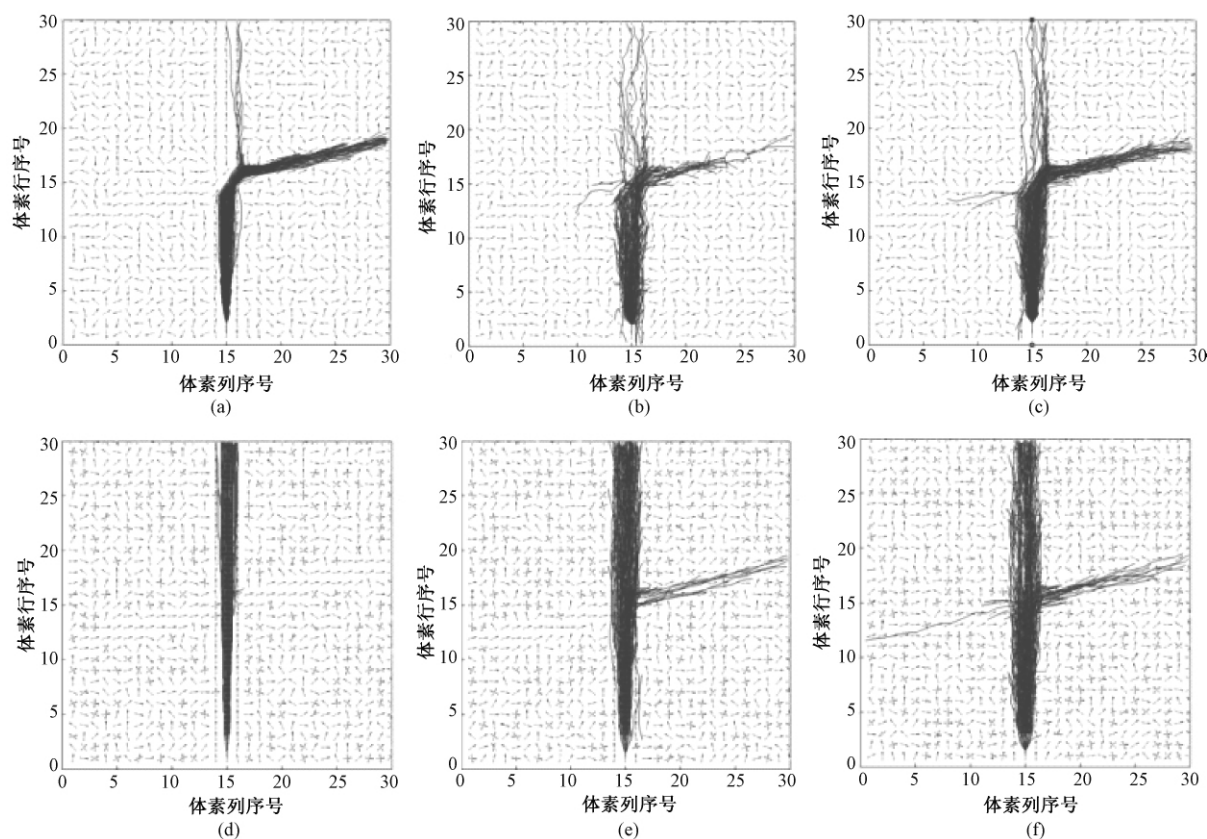


图7 相交 75° 纤维跟踪算法执行结果。(a)~(c)基于DTI模型在 $\gamma = 5\%$ 、 10% 、 15% 噪声干扰下的纤维跟踪结果;(d)~(f)高阶张量模型在 $\gamma = 5\%$ 、 10% 、 15% 噪声干扰下的纤维跟踪结果

Fig. 7 Fiber tracking result in 75° crossing. (a)~(c) Fiber tracking result in $\gamma = 5\%$ 、 10% 、 15% based on DTI model; (d)~(f) Fiber tracking result in $\gamma = 5\%$ 、 10% 、 15% based on higher order model

纤维路径描述。

4.2 实际临床数据测试

用一组真实的DW-MRI数据进行分析,对比DTI成像方法说明高阶张量模型在复杂纤维结构下的局部张量模型的求解优势。所用的实际人脑数据来自哈佛大学医学院附属医院(Brigham and Women's Hospital, Brockton VA Hospital, McLean Hospital),并已经得到授权。这些数据采集参数为:3-T GE系统,TR=17000ms、TE=78 ms。图像视场为24 cm,分辨率为144像素 \times 144像素,层数为85,层厚度为1.7 mm。51个梯度方向($b=900\text{s/mm}^2$),8个基线扫描($b=0$)。

选取DW-MRI一帧数据的部分区域进行高阶张量成像分析。图8显示了对数据进行6阶张量建模的成像结果。分析1根纤维区域、2根纤维区域、3根纤维区域的细节放大图可知,在不同数目纤维交叉的区域中,由高阶张量模型可以较好得到交叉纤维的局部纤维走向。

对这组数据分别进行DTI成像和高阶张量成像

分析,图9(a)是对一帧数据进行DTI成像的局部范围放大结果图。图9(b)是对同样一帧数据采用六阶张量成像的结果图。由图9可知,DTI的二阶建模方法获得的局部张量模型局限性较大,基本无法区分两根及两根以上纤维交叉情况,用本研究提出的高阶张量特征提取算法在一定程度上可以很好解决纤维交叉问题。

5 讨论和结论

通过利用合成数据和实际临床数据的研究可以看出,在复杂纤维交叉情况下,基于高阶张量的建模方法能更精确描述局部张量模型。相比于传统的DTI模型,利用本研究提出的基于高阶张量模型的特征提取算法可以快速、准确地提取两根或者三根纤维交叉情况下的局部纤维方向,为脑白质纤维跟踪提供准确的局部方向信息。

但在高阶张量模型试验中,单纯提高对离散球体模型的细分次数或者增加高阶模型阶次得到的特征提取结果精度并没有明显改善。由此可以看

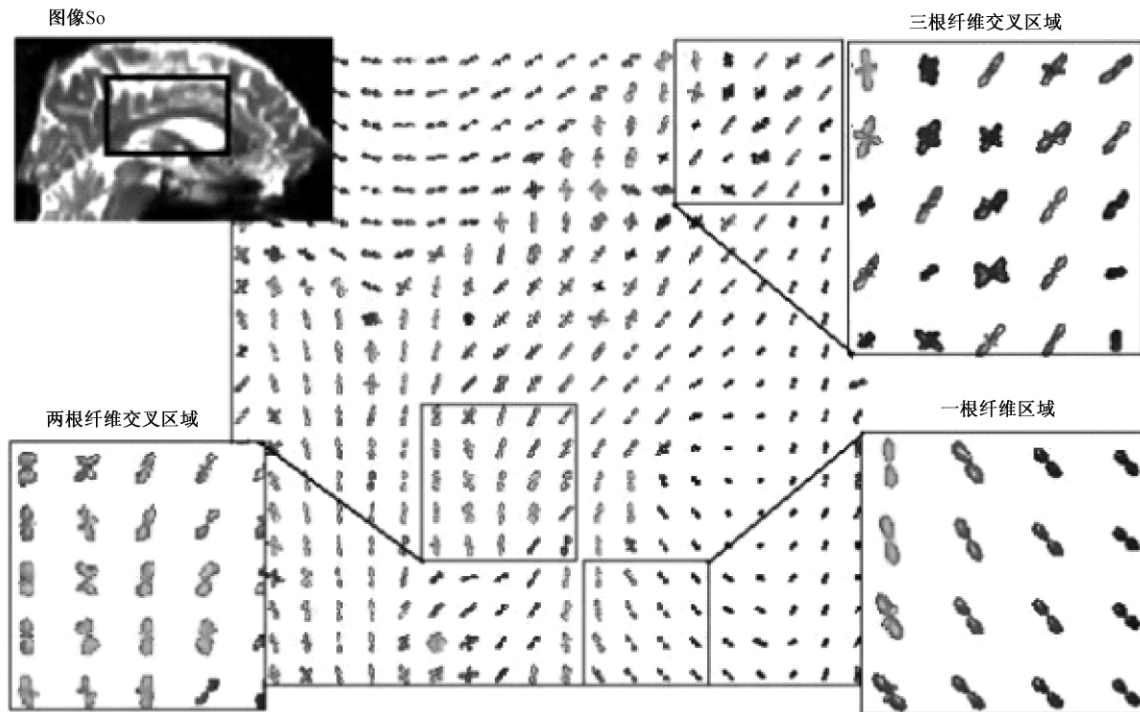


图8 左上角为 S_0 的图像,对这组 DW-MRI 数据进行 6 阶张量模型估计(其中包括对 1 根纤维区域、2 根纤维交叉区域和 3 根纤维交叉区域的分析)

Fig.8 The S_0 image is shown on the top left. The 6th-order diffusion tensors estimated using the DW-MRI dataset (including one-fiber region , 2-fiber region and 3-fiber region)

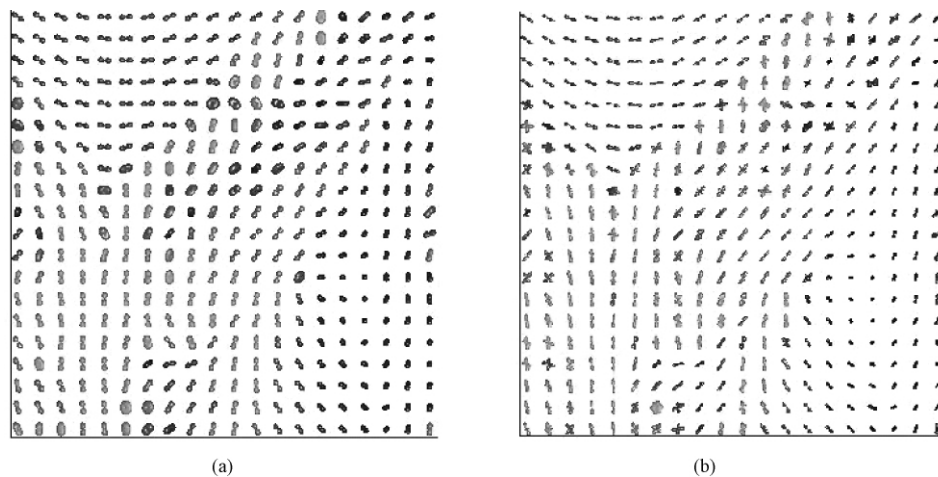


图9 局部张量成像。(a) DTI 局部成像;(b) 6 阶扩散张量成像

Fig.9 Local tensor imaging. (a) The DTI model shown; (b) 6th-order tensor model

出要提高特征提取精度不能只依赖模型阶次的提高,应该寻找更能精确反应局部各向异性的模型,得到更为准确的局部特征方向,为解决小角度、多纤维等复杂的纤维结构提供可能性。

利用高阶张量模型描述复杂的纤维微结构是解决当前 DTI 模型固有缺陷的有效方法。但是随着阶数的增加,通过符号计算方法获取这种以非线性

多项式描述的扩散张量函数极值的方法,显得计算复杂且不稳定。在高阶张量模型基础上,利用网格细分和迭代搜索的思想,本研究提出一种计算任意阶次张量模型特征方向的方法。经过仿真数据和实际数据测试表明,本算法显示出对多纤维、小交角的纤维具有良好的识别能力及纤维特征方向的计算精度。该方法避免了利用多项式极值求解张

量特征方向效率较低的问题,从而使利用高阶张量模型解决实际临床数据问题成为可能。

所提出的高阶张量特征提取算法对于小角度纤维交叉的特征求解仍存在局限性,在今后的研究中,我们要优化算法及模型,在提高纤维识别精度的同时,对纤维分叉、扇型、瓶颈型等其他复杂纤维结构进行分析,推动大脑纤维三维重构研究。

参考文献

- [1] Cheng Jian, Ghosh A, Deriche R, *et al.* Model-Free, Regularized, Fast, and Robust Analytical Orientation Distribution Function Estimation [C] //MICCAI 2010, Part I. Berlin: Springer-Verlag, 2010: 648 – 656.
- [2] Tuch D. Q-ball imaging [J]. Magnetic Resonance in Medicine, 2004, **52**(6): 1358 – 1372.
- [3] Liu Chunlei, Acar B, Moseley ME. Characterizing non-gaussian diffusion by using generalized diffusion tensors [J]. Magnetic Resonance in Medicine, 2004, **51**: 924 – 937.
- [4] Barmpoutis A, Vemuri BC. A unified framework for estimating diffusion tensors of any order with symmetric positive-definite constraints [C] // Proc IEEE Int Symp Biomed Imaging. Piscataway: IEEE Press, 2010: 1385 – 1388.
- [5] Parker G., Haroon H, Wheeler-Kingshott C. A framework for a streamline based probabilistic index of connectivity(PICO) using a structural interpretation of MRI diffusion measurements [J]. Journal of Magnetic Resonance Imaging, 2003, **18**(2): 242 – 254.
- [6] Basser P, Pajevic S. A normal distribution for tensor-valued random variables: applications to diffusion tensor MRI [J]. IEEE Trans Med Imag, 2003, **22**: 785 – 794.
- [7] Moakher M, Norris AN. The closest elastic tensor of arbitrary symmetry to an elasticity tensor of lower symmetry [J]. Journal of Elasticity, 2006, **85**(3): 215 – 263.
- [8] Barmpoutis A, Hwang MS, Howland D, *et al.* Regularized positive-definite fourth order tensor field estimation from DW-MRI [J]. NeuroImage, 2009, **45**(1): 153 – 162.
- [9] Berg C. The multidimensional moment problem and semigroups [J]. Moments in mathematics, American Mathematical Society, 1987, **37**: 110 – 124.
- [10] Rudin W. Sums of squares of polynomials [J] Am. Math. Monthly, 2000, **107**: 813 – 821.
- [11] Mori S, Van Zijl. Fiber tracking: Principles and strategies—A technical review [J]. NMR in Biomedicine, 2002, **15**: 468 – 480.